


CESTE

Escuela Internacional de Negocios

Zaragoza (España)



Programa de hoy

1. Roles en el ecosistema de datos

1. Skills para roles más comunes
2. Roles Similares
3. Recomendaciones

2. Databricks Fundamentales

1. Los 3 fundamentales (Spark, Delta Lake, UC)
2. Data Warehouse vs Data Lake vs Data Lakehouse
3. Ecosistema de datos actual & Databricks scope

3. Arquitectura de Objetos en UC

1. Objetos en UC
2. Account>Workspace>Cluster>Jobs


4. Clusters

1. Qué es
2. Tipos de accesos
3. Tipos de Clusters


ECOSISTEMA DE ROLES EN DATA



Introducción a la Asignatura | Data roles ecosystem I



Introducción a la Asignatura | Data roles ecosystem II



DATABRICKS FUNDAMENTALES



Databricks Fundamentales | Los 3 Pilares



- Motor distribuido de procesamiento que permite **trabajar en paralelo sobre grandes volúmenes de datos**, tanto batch como streaming.
- Organiza el trabajo con **Driver, Workers, Executors y DAGs**,



- Formato de almacenamiento que añade **ACID, versionado, y esquema evolutivo** sobre archivos Parquet.
- Permite **time travel, upserts, merges optimizados y data quality checks**, ideal para pipelines medallion.


Unity Catalog



databricks

- Sistema centralizado para gestionar **seguridad, permisos, catalogación y lineage de datos** entre diferentes Workspaces.
- Permite gobernanza unificada con **control de acceso a nivel de catálogo, esquema, tabla y columna** (incluida datos sensibles/PII).

Databricks Fundamentales | Data Warehouse



Data Warehouse


✓ Pros:

1. Estructura clara y gobernabilidad
2. Ideal para **BI y SQL tradicional**

✗ Cons:

1. Dificil manejar datos **no estructurados** (audio, video, texto)
2. No está pensado para **Machine Learning** ni **ciencia de datos**
3. Poco flexible ante grandes volúmenes o variedad de datos

Databricks Fundamentales | Data Lake



Data Lake

✓ Pros:

1. Escalable y económico (almacenamiento en bruto)
2. Acepta **cualquier tipo de datos** (estructurados o no)

✗ Cons:

1. **Sin control de calidad** → puede volverse una "ciénaga de datos"
2. Bajo rendimiento para consultas
3. Mala integración con herramientas BI
4. No garantiza integridad ni transacciones

Databricks Fundamentales | Data Lakehouse


Data Warehouse

Pros:

1. Estructura clara y gobernabilidad
2. Ideal para BI y SQL tradicional

Cons:

1. Difícil manejar datos **no estructurados** (audio, video, texto)
2. No está pensado para **Machine Learning** ni ciencia de datos
3. Poco flexible ante grandes volúmenes o variedad de datos



Data Lake

Pros:

1. Escalable y económico (almacenamiento en bruto)
2. Acepta cualquier tipo de datos (estructurados o no)


Cons:

1. Sin control de calidad → puede volverse una "ciénaga de datos"
2. Bajo rendimiento para consultas
3. Mala integración con herramientas BI
4. No garantiza integridad ni transacciones


El **Data Lakehouse** es la **evolución natural** que:

1. Une lo **mejor del Data Warehouse** (gobierno, fiabilidad, rendimiento)
2. Con lo **mejor del Data Lake** (flexibilidad, diversidad, escalabilidad)

Databricks | Ecosistema de Datos I



Databricks | Ecosistema de Datos II



DEMO
APERTURA DE CUENTA EN DATABRICKS
EXPLORACIÓN DEL ENTORNO

SPARK & ARQUITECTURA UC




Arquitectura UC | Objetos en UC


Nivel 1 — Catálogo (máximo nivel de organización y gobernanza) Agrupa y aísla los recursos de datos a nivel corporativo. Normalmente refleja unidades organizativas, entornos (dev/test/prod) o dominios globales.

Nivel 2 — Esquema (espacio lógico de trabajo por proyecto o equipo) Subdivisión dentro del catálogo para organizar datos por caso de uso, área funcional o equipo de trabajo, aislando su contexto operativo.

Nivel 3 — Objetos (donde realmente residen o se consumen los datos)
Elementos concretos dentro del esquema:
Tablas → datos estructurados gestionados por UC
Vistas → consultas reutilizables y gobernadas
Volúmenes → archivos crudos o semiestructurados en cloud storage
Funciones → lógica reutilizable para transformar o proteger datos



Arquitectura | Nivel Organizativo en Databricks




DEMO
CREACIÓN DE OBJETOS EN UC
TABLAS DELTA
INTRO A PYSPARK

CLUSTER



Clusters | ¿Qué es?



Clusters | Modos de Acceso

Single User Access Mode



- **Solo una identidad** puede usarlo: el propietario.
- Autenticación y permisos controlados al 100% por **Unity Catalog** + IAM.
- Ideal para **seguridad alta**, acceso a datos sensibles, ML, Service Principals.

=> Ejemplo de contexto:
"Estoy desarrollando un modelo de ML con acceso a datos sensibles: cluster Single User."

Shared Access Mode



- **Varias personas** pueden usar el mismo cluster.
- Cada notebook se ejecuta con la **identidad real del usuario**.
- Permite **colaboración** y mantiene permisos individuales.

=> Ejemplo de contexto:
"Estamos editando notebooks en equipo y cada uno ve solo lo que tiene permiso—Shared Mode."

No Isolation Shared Access Mode



- Todos los usuarios comparten la **misma identidad** técnica.
- **No hay control de credenciales** individuales.
- **No soporta Unity Catalog** ni passthrough.

=> Ejemplo de contexto:
"Uso un cluster antiguo para pruebas rápidas con datos no sensibles."

Clusters | Tipos de Clusters



All-Purpose Clusters

- ideales para el **desarrollo interactivo**, las pruebas y la colaboración.
- Espacio de trabajo compartido para **crear y experimentar**



JOB Clusters

- diseñados específicamente para ejecutar **tareas programadas** o activadas.
- Se activan para la tarea y **se apagan automáticamente cuando terminan**, lo que los hace ideales para ETL de producción.



Clusters Pools

- una forma de precalentar los recursos informáticos para que los clústeres **se inicien más rápido**.
- Perfectos para entornos con **trabajos cortos frecuentes**.



SQL Warehouses

- optimizados para consultas SQL y herramientas de BI.

DEMO

Exploración de Datos con Spark
DBUtils
Dashboards Intro